



Apresentação de Resultados

Análise exploratória e descritiva de indicadores – 2024

Uber

Sumário

Motivação, Contexto e Objetivo do Estudo – 3

Clusterização de Status das Corridas – 4

Impacto Financeiro das Corridas – 5

Análise das Corridas Incompletas – 6

Corridas, Receita, Ticket Médio e Distância média – 8

Motivação, Contexto e Objetivo do Estudo

Motivação e Objetivo do Estudo

A principal **motivação** para confecção deste case de estudo é fortalecer minhas competências com Análise de Dados. O **objetivo** aqui é explorar principalmente as habilidades com **SQL**, **Storytelling** e **Negócios**, realizando análises **exploratória** e **descritiva** sobre os **KPIs**.

Contexto e detalhes sobre o dataset

Os dados presentes neste dataset vão ser explorados no **intuito** de entender o comportamento das corridas e da receita, na identificação de padrões de séries temporais e clusters, além de recomendar ações sempre que possível.

Existem limitações no dataset (falta de dados) que impossibilitam de responder algumas perguntas, deixarei sempre um disclaimer quando essas situações acontecerem.

Clusterização de Status das Corridas

Agrupamento para Análise

Os diferentes status das corridas foram reorganizados em três grupos para simplificar a análise:

Concluídas → Completed (geram receita real)

Canceladas → Cancelled by Driver, Cancelled by Customer, No Driver Found (não geram receita)


Incompletas → Incomplete (geram receita potencial não realizada)

Essa clusterização permitiu distinguir claramente entre receita efetiva, receita perdida e impacto apenas operacional, servindo de base para as análises seguintes.

Impacto Financeiro das Corridas

Corridas, Receita Realizada e Receita Potencial Perdida

No período analisado, houveram **150 mil** solicitações de corridas, que ficaram distribuídas nos seguintes clusters:



A receita anual foi de **₹ 47,2 milhões**, com um ticket médio de **₹ 508,17**.

Receita potencial perdida de **₹ 4,5 milhões** em corridas que foram iniciadas mas não concluídas



Nota: Por ser uma informação estratégica das empresas do setor, não existe informação pública que diga qual o percentual de corridas concluídas em escala global, entretanto, dentro do seu próprio blog institucional, a Uber recomenda uma meta de taxa de cancelamento para os motoristas de até 5% (cálculo: **concluídas / (concluídas + canceladas)**), feito em cima das últimas 100 corridas). Aplicando este racional, o dataset apresenta uma taxa de cancelamento de **34%**, o que é uma média muito acima da meta de 5%.

Impacto Financeiro das Corridas

Corridas incompletas geram 8,8% de perda de receita potencial


Corridas incompletas custaram ₹ 4,5MM, divididos em 3 motivos:

Customer Demand

Vehicle Breakdown

Other Issue

Distribuição de corridas equilibrada (≈33% cada motivo), ou seja, não há causa única, mas somatória de fatores




As corridas incompletas apresentam **tempos médios de espera** de 6min e **duração média** de 20min, resultados praticamente idênticos entre os três motivos, representando perdas iguais de receita. Isso mostra que o impacto não é operacional.

Já entendemos o impacto financeiro das corridas incompletas, o próximo passo é analisar **quando** esses eventos acontecem, para identificar padrões temporais e direcionar ações operacionais.

Motivo de Corridas Incompletas

Sem motivo predominante, abordagens holísticas recomendadas


Entre 16:00 e 19:00, o número de corridas ultrapassa 1 desvio padrão acima da média, evidenciando uma demanda de cancelamento acima do normal.



Motivo	Freq. Absoluta	Freq. Relativa	Freq. Relativa Acumulada
Vehicle Breakdown	820	34,4%	34,4%
Customer Demand	809	33,9%	68,3%
Other Issue	757	31,7%	100,0%

Os motivos de corridas incompletas estão bem equilibrados, indicando que não há um fator único predominante que explique a maior parte das falhas.


Ao observar a distribuição do cluster dos status das corridas por intervalo no ano de 2024, não existe variação estatística significativa do % Incompletas no horário de **pico**. Isso sugere que melhorias precisam ser abordadas de forma holística, realizando uma análise **qualitativa**; enviando pesquisas via e-mail/app para os clientes e motoristas, afim de entender alguma oportunidade nesse horário de pico que possa ser mitigada pela Uber.




Corridas, Receita, Ticket Médio e Distância média

Trade-off prejudicial nos meses Janeiro, Julho e Outubro

Março teve o **melhor** resultado de número de corridas, enquanto **fevereiro** apresentou o **pior**.



Nem sempre mais corridas significam mais receita. Há meses com maior volume, mas ticket médio menor, indicando possível presença de campanhas promocionais ou aumento de corridas curtas.



É possível observar que os meses **Jan**, **Jul** e **Out** tiveram tickets médios baixos, e com a distância média por corrida **acima da média anual**, sugerindo indícios de promoções no período, um trade-off prejudicial.

Já em **Maio**, a distância média percorrida foi **abaixo da média anual**, indicando **corridas mais curtas** no período.

Nota: Dataset **não** contém dados de **descontos/vouchers**. Inferência baseada na razão entre **ticket médio dos três meses e o anual (-0,95%)**, e a razão entre a **distância média dos três meses e a anual (+0,36%)**.

E recomendado ao time de engenharia de dados o enriquecimento do dataset, disponibilizando as colunas de promoções para aprofundar o estudo.

*Análise realizada utilizando SQL e Excel.
Case para portfólio.*

Obrigado!

Nikollas Eugênio Pitombeira Pimentel

Analista de Dados

Uber